

Metapi 四个 Issue 修复演示

真实网页截图、接口调用示例与验证路径

演示地址	http://127.0.0.1:5174/
覆盖范围	#591 Rerank / #590 路由优先级 / #586 Coding Plan v3 / #585 渠道失败隔离
截图说明	截图均来自当前本地运行实例；演示过程未保存或修改站点、账号、路由配置。




图 1. 登录后的控制台首页。右侧站点信息中可看到本地实例已有站点数据。

1. 站点独立最大并发

每个站点拥有自己的最大并发上限。截图中的 concurrency-site 配置为 1，其他站点仍显示“不限制”，说明限制按站点隔离，而不是全局共享一个数字。超过上限的请求会在该站点自己的并发队列中等待。




图 2. 站点管理表格：concurrency-site 的“最大并发”为 1，其他站点为“不限制”。




图 3. 编辑站点弹窗：右下字段保存值为 1，下方说明明确表示同一站点请求共享该上限并排队。

2. 路由优先级 P0 / P1

路由页面将通道按优先级桶展示。拖动通道到新的优先级层后，前端会按路由压缩为连续的 P0、P1、P2...，服务端保存后仍以 `priority` 数字作为唯一排序依据。

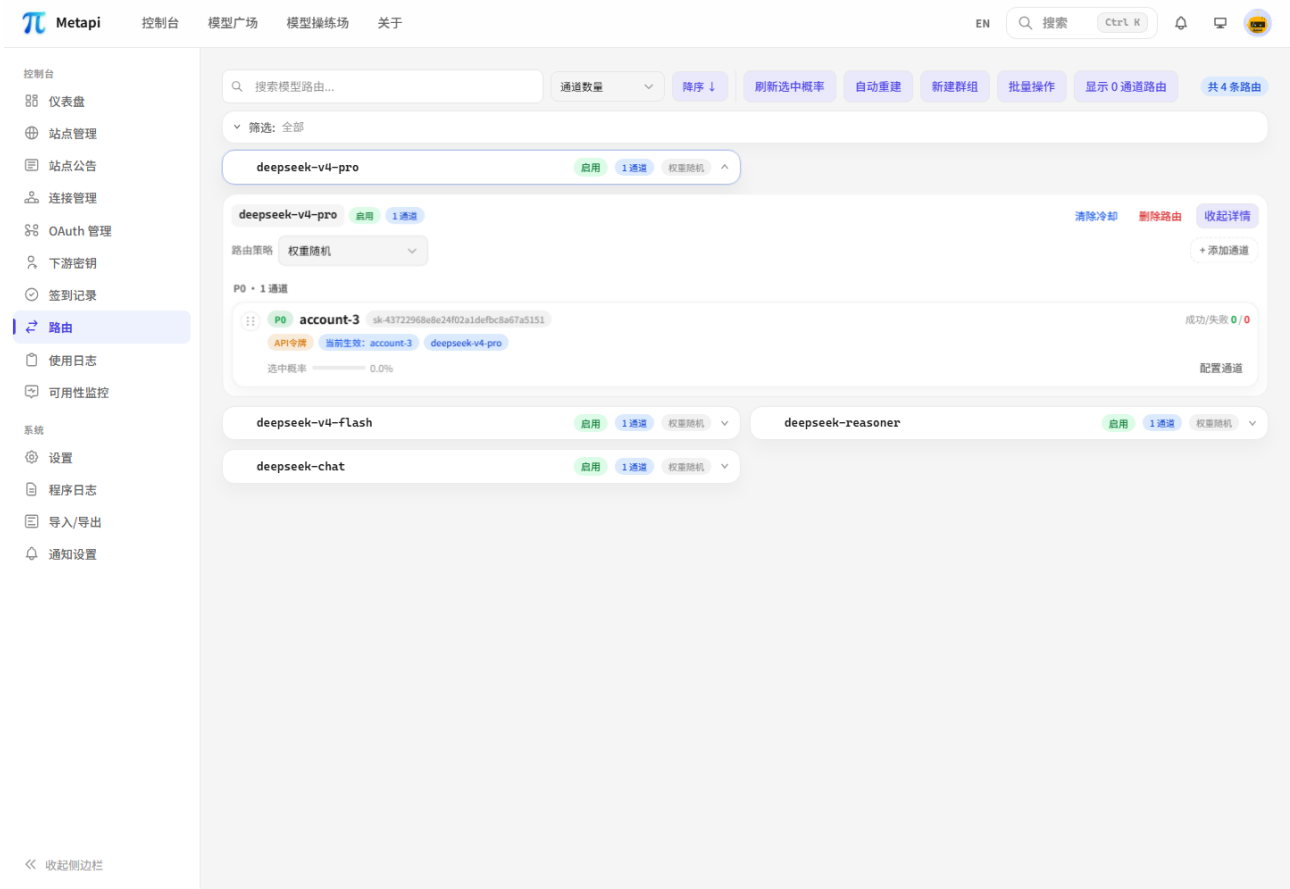


图 4. 展开 `deepseek-v4-pro` 路由后的真实页面：通道显示在 P0 优先级桶中，并保留成功/失败统计和配置通道入口。

演示操作：进入“路由” -> 点击任一路由卡片展开 -> 拖动通道到目标优先级桶 -> 等待保存提示。批量编辑时，API 返回结果会按 `priority`、`id` 排序。

3. Rerank 接口（#591）

新增接口路径为 POST /v1/rerank，使用下游 API Key 鉴权。请求会被路由到支持 rerank 的上游站点，返回 OpenAI 兼容风格的相关度排序结果。当前本地实例未在演示中新增上游凭据，因此只验证了鉴权边界：未携带 Authorization 请求实际返回 HTTP 401。

PowerShell 调用示例

```
$headers = @{
    Authorization = "Bearer <你的 Metapi API Key>"
    "Content-Type" = "application/json"
}
$body = @{
    model = "bge-reranker-v2-m3"
    query = "如何配置 Metapi 的代理接口"
    documents = @(
        "Metapi 支持 OpenAI 兼容的聊天接口。"
        "站点页面可以配置上游 API 地址和账号令牌。"
        "重排序用于按查询相关度排列文档。"
    )
    top_n = 2
    return_documents = $true
} | ConvertTo-Json -Depth 5
Invoke-RestMethod -Uri "http://127.0.0.1:4000/v1/rerank" `
    -Method Post -Headers $headers -Body $body
```

预期结果结构

```
{
  "id": "rerank-...",
  "results": [
    { "index": 1, "relevance_score": 0.98, "document": { "text": "... " } },
    { "index": 0, "relevance_score": 0.72, "document": { "text": "... " } }
  ],
  "model": "bge-reranker-v2-m3"
}
```

鉴权验证：POST /v1/rerank 不带 Authorization 返回 401，响应为 “Missing Authorization, x-api-key, x-goog-api-key, or key query parameter”。

4. Coding Plan v3 (#586)

上游地址拼接现在会识别 URL 末尾的 /vN 版本段，避免把下游的 /v1 再重复拼接到 Coding Plan v3 路径之后。

场景	拼接结果
上游 Base URL	https://example.com/api/coding/v3
下游请求路径	/v1/chat/completions
修复后的实际上游路径	/api/coding/v3/chat/completions

5. 渠道失败隔离 (#585)

429 用量限流只冷却本次实际失败的通道，不再按同一凭据把冷却状态扩散到兄弟通道，也不会写入站点级运行时熔断。这样可以保留同一站点下其他健康通道的可用性。

验证项	结果
失败通道	进入用量冷却，参与后续重试分类
同凭据其他通道	不扩散冷却状态
站点运行时熔断	429 不再写入站点级熔断

6. 建议测试顺序

下面的步骤可以在本地 run 页面和 API 客户端中复现本次演示。

步骤	操作
1	打开 <code>http://127.0.0.1:5174/</code> ，使用当前实例的管理员令牌登录。
2	进入“站点管理”，编辑目标站点，填写 1-100000 的最大并发，保存后回到表格确认数值。
3	进入“路由”，展开路由卡片，确认通道位于 P0；拖动到新桶后确认保存。
4	准备支持 rerank 的上游账号和下游 API Key，执行本报告第 3 节的 POST 请求。
5	执行单线程测试，避免本机并行 worker 的内存峰值： <code>npx vitest run --pool=threads --poolOptions.threads.singleThread=true ...</code>

已完成的工程验证

类型检查、schema 单元测试、repo drift check，以及 rerank、路由、tokenRouter、endpoint flow 相关单线程 Vitest 测试均已通过。并行 Vitest worker 在本机曾出现 OOM/UNKNOWN，因此复测建议使用单线程参数。

交付物	状态
本地网页截图	已生成 5 张真实页面截图并嵌入本报告
接口演示说明	已给出 Rerank 请求、响应结构和鉴权验证
代码变更	保留在当前本地项目工作区，未覆盖用户已有修改